

# Estrategias RAG adaptativas para razonamiento multi-hop

## Evaluación de accuracy, costo computacional, robustez y generalización en benchmarks MC-500

Ion Harteker   Felipe Andres Sidiropulos   Camila Di Paola  
Laura Victoria Lescano   Alan Schadan  
Universidad de San Andrés

### Resumen

Este trabajo evalúa cuándo conviene responder directamente con un modelo de lenguaje y cuándo conviene agregar recuperación externa en preguntas multi-hop. Construimos MuSiQue-MC-500, una versión multiple-choice y auditable de MuSiQue con corpus recuperable, y comparamos cuatro sistemas: S0, respuesta directa sin contexto; S1, RAG fijo top-5; S2, RAG adaptativo; y S3, una variante FLARE-like de recuperación activa. Además analizamos S5, un meta-router post-hoc que selecciona entre S0–S3, y S4, un auditor factual focalizado.

La evaluación principal se realiza sobre gpt-5-nano, gpt-5-mini y gpt-4.1-mini. S3 alcanza la mayor accuracy individual en los tres modelos; con gpt-5-mini obtiene 80.8 % con 2296 tokens promedio. Como validación externa, replicamos la comparación S0–S3 con gpt-5-mini en HotpotQA-MC-500 y 2Wiki-MC-500, donde las estrategias con recuperación también superan al baseline directo. S5 muestra complementariedad entre sistemas: *confidence-then-cost* alcanza 81.4 % con 1258 tokens seleccionados, aunque es post-hoc y no debe interpretarse como sistema deployable. En robustez, S3-MC lidera en clean/noisy, pero S1 resulta más estable en adversarial. Concluimos que RAG no es una decisión binaria: el problema central es decidir por caso qué estrategia de memoria usar, cuánto costo pagar y cuándo auditar evidencia.

### 1. Introducción

Los modelos de lenguaje pueden responder muchas consultas desde conocimiento paramétrico, pero en preguntas multi-hop suelen necesitar combinar varios hechos. En esos casos, una respuesta directa puede fallar por memoria incompleta, confusión de entidades o mezcla de evidencia parcial. Retrieval-Augmented Generation (RAG) (Lewis et al., 2020) aborda este problema incorporando documentos recuperados en tiempo de inferencia:

el modelo no responde solo desde sus parámetros, sino también desde una memoria externa.

RAG, sin embargo, no es gratis. Recuperar siempre aumenta tokens, latencia y exposición a contexto irrelevante. Además, si la evidencia recuperada es incompleta o engañosa, un sistema más complejo puede reforzar errores en lugar de corregirlos. La pregunta experimental de este trabajo es entonces concreta: *¿qué se gana y qué se pierde al pasar de un LLM directo a estrategias RAG fijas, adaptativas y activas en preguntas multi-hop?*

Para responderla, evaluamos una familia de sistemas sobre MuSiQue-MC-500. El diseño compara accuracy, tokens, latencia, tasa de recuperación y robustez. También estudia si los errores de distintos sistemas son complementarios: si S0, S1, S2 y S3 aciertan en casos distintos, entonces un router podría mejorar el balance entre rendimiento y costo.

Las contribuciones son cinco. Primero, construimos una evaluación homogénea sobre 500 preguntas multi-hop multiple-choice con corpus recuperable. Segundo, comparamos estrategias RAG en tres modelos de distinta capacidad. Tercero, extendemos la comparación S0–S3 a HotpotQA-MC-500 y 2Wiki-MC-500 con gpt-5-mini. Cuarto, analizamos un meta-router post-hoc como estimación del margen para routers predictivos. Quinto, incorporamos una evaluación de robustez con corpus limpio, ruidoso y adversarial, más una auditoría factual focalizada sobre errores de S3.

Nuestra contribución de diseño, más allá de adaptar ideas de FLARE y verificación factual, es la construcción de S5 como meta-router post-hoc que cuantifica complementariedad entre estrategias, y de S4 como auditor factual aplicado selectivamente sobre errores de S3.

La hipótesis de fondo es que no existe una estrategia universalmente dominante. Si una pregunta puede resolverse por conocimiento paramétrico, S0 puede ser suficiente y más barato. Si requiere

evidencia explícita, S1 puede mejorar la respuesta. Si la evidencia recuperada es débil, S2 puede ahorrar costo evitando contexto inútil, aunque corre el riesgo de no recuperar cuando debería. Si la pregunta es difícil, S3 puede corregir una hipótesis inicial mediante recuperación activa. El objetivo experimental es medir estas tensiones con una misma grilla, no solo reportar el sistema con mayor accuracy.

## 2. Trabajo relacionado

RAG combina recuperación y generación para tareas intensivas en conocimiento (Lewis et al., 2020). Trabajos como REALM (Guu et al., 2020) y Atlas (Izacard et al., 2023) muestran que la memoria externa puede mejorar modelos en preguntas de conocimiento, mientras que ALCE (Gao et al., 2023) enfatiza la atribución de respuestas a evidencia. En todos los casos, la dificultad no es solo recuperar documentos, sino usar correctamente el contexto recuperado.

Las preguntas multi-hop requieren enlazar hechos y entidades. HotpotQA (Yang et al., 2018), 2WikiMultiHopQA (Ho et al., 2020) y MuSiQue (Trivedi et al., 2022) fueron diseñados para evaluar este tipo de razonamiento. Elegimos MuSiQue porque sus preguntas se construyen por composición de pasos simples, lo cual reduce la posibilidad de resolverlas por memorización directa o coincidencia superficial de palabras.

La recuperación adaptativa y activa busca evitar que RAG sea una operación fija. FLARE (Jiang et al., 2023) propone generar primero, detectar necesidad de evidencia y recuperar después. Self-RAG (Asai et al., 2024) incorpora señales de reflexión sobre cuándo recuperar y criticar. Nuestro trabajo no entrena un modelo nuevo; evalúa políticas implementables sobre un pipeline común y mide explícitamente costo en tokens y robustez.

Finalmente, la verificación factual cumple un rol distinto del sistema de respuesta. Benchmarks como FEVER (Thorne et al., 2018) distinguen evidencia soportada, refutada o insuficiente. En nuestro pipeline, S4 se usa como auditor focalizado: no compete masivamente con S0–S3, sino que examina casos conflictivos donde una estrategia compleja puede sobreconfiar en evidencia débil.

## 3. Benchmark y dataset

Antes de fijar el benchmark final probamos versiones multiple-choice de 2Wiki, HotpotQA, Multi-

HopRAG y MuSiQue con S0 directo sobre 100 preguntas. El objetivo era evitar saturación: si un modelo sin contexto supera aproximadamente 80 %, queda poco margen para medir el valor de RAG. MultiHopRAG quedó saturado para los tres modelos; 2Wiki y HotpotQA quedaron cerca del umbral para gpt-5-mini; MuSiQue mantuvo dificultad adecuada, con S0 en 0.44 para gpt-4.1-mini, 0.69 para gpt-5-mini y 0.66 para gpt-5-nano. La tabla completa de saturación se reporta en el Apéndice.

Por esa razón, MuSiQue-MC-500 se mantiene como benchmark principal para el análisis profundo, la grilla por modelos, robustez, S4 y S5. HotpotQA y 2Wiki se usan luego como validación externa: aunque están más cerca de saturarse con gpt-5-mini, permiten verificar si la ventaja relativa de recuperar evidencia se mantiene fuera de MuSiQue bajo el mismo formato multiple-choice.

MuSiQue-MC-500 contiene 500 preguntas derivadas de MuSiQue. Cada ejemplo incluye pregunta, cuatro opciones, respuesta correcta y evidencia asociada para construir un corpus recuperable. Convertimos a multiple-choice para usar accuracy exacta y evitar ambigüedad de evaluación en respuestas abiertas. Este formato permite comparar sistemas RAG de forma limpia, pero introduce riesgos: opciones truncadas, mezclas de idioma, sesgos de longitud, opciones de tipo semántico distinto o sesgos de posición pueden inflar artificialmente el score.

Por eso el dataset fue auditado antes de las corridas finales. Se balanceó la posición correcta entre A/B/C/D, se removieron booleanas problemáticas, se corrigieron distractores truncados y se revisaron casos de solapamiento entre gold y distractores. Además se construyó un corpus RAG con 6000 documentos, 12 contextos por pregunta, qrels e índice de recuperación. Así, S1, S2 y S3 operan sobre la misma evidencia y sus diferencias son comparables.

La construcción siguió cuatro pasos. Primero, se tomó la pregunta original y su contexto de soporte. Segundo, se generaron distractores que mantuvieran el mismo tipo semántico que la respuesta correcta: nombres con nombres, ubicaciones con ubicaciones, organizaciones con organizaciones. Tercero, se armó el prompt multiple-choice separando la pregunta limpia usada para recuperar de la pregunta con opciones usada para responder. Cuarto, se exportaron documentos y qrels para que todos los sistemas con RAG consultaran exactamente el mismo corpus. Esta separación es importante:

permite que una diferencia entre S1, S2 y S3 se atribuya a la política de uso de evidencia y no a cambios en el dataset.

La auditoría fue necesaria porque los primeros lotes de generación tenían atajos. Algunas preguntas mezclaban opciones booleanas con entidades, otras tenían distractores truncados o respuestas correctas mucho más cortas que el resto. En esos casos, un modelo podía acertar por formato sin resolver el razonamiento multi-hop. La versión final reduce estos artefactos y por eso permite interpretar la accuracy como una señal más cercana a comprensión y uso de evidencia.

#### 4. Sistemas y diseño experimental

La Tabla 1 resume los sistemas evaluados. S0 mide conocimiento paramétrico; S1 representa RAG clásico; S2 prueba si conviene recuperar selectivamente; S3 evalúa recuperación activa; S4 audita factualidad en casos seleccionados; y S5 estima, de forma post-hoc, cuánto margen existe para seleccionar entre sistemas.

La evaluación principal usa gpt-5-nano, gpt-5-mini y gpt-4.1-mini. Estos modelos permiten separar el efecto de la estrategia RAG del efecto de capacidad del modelo base. Se reportan accuracy, tokens promedio, latencia, retrieval rate, mejora contra S0 y accuracy por 1000 tokens. Para robustez se evalúan 100 preguntas en tres condiciones: *clean*, *noisy* con 12 distractores aleatorios por pregunta, y *adversarial* con 12 distractores semánticamente similares.

Las cuatro hipótesis evaluadas son: H1, RAG debe mejorar frente a S0 si el benchmark requiere evidencia multi-hop; H2, la recuperación activa debe aumentar accuracy pero también costo; H3, la adaptatividad debe ahorrar tokens, aunque puede perder accuracy si la política subestima preguntas difíciles; y H4, si los sistemas cometen errores distintos, entonces S5 debería revelar complementariedad. Estas hipótesis ordenan la lectura de los resultados: una mejora de accuracy no alcanza si duplica tokens, y una reducción de costo no alcanza si pierde demasiadas respuestas correctas.

| Sistema | Qué hace                                                             | Cuándo recupera                                     | Rol experimental                                               |
|---------|----------------------------------------------------------------------|-----------------------------------------------------|----------------------------------------------------------------|
| S0      | LLM directo con pregunta y opciones.                                 | Nunca.                                              | Baseline de conocimiento paramétrico y chequeo de saturación.  |
| S1      | RAG fijo con top-5.                                                  | Siempre.                                            | Baseline fuerte con memoria externa constante.                 |
| S2      | RAG adaptativo con señales del recuperador.                          | Solo si la política decide que el caso lo requiere. | Trade-off entre accuracy y costo en tokens.                    |
| S3      | FLARE-like MC: predice, estima incertidumbre y revisa con evidencia. | Según confianza y señales del caso.                 | Mide si la recuperación activa aumenta accuracy a mayor costo. |
| S4      | Auditor factual de claims y evidencia recuperada.                    | Casos conflictivos seleccionados.                   | Capa de soporte, abstención y análisis de errores.             |
| S5      | Meta-router post-hoc sobre S0–S3.                                    | No recupera; selecciona una salida ya generada.     | Cuantifica complementariedad entre estrategias.                |

Tabla 1: Resumen de sistemas evaluados. S4 y S5 no son sistemas online comparables de forma directa con S0–S3: S4 audita y S5 selecciona post-hoc.

## 5. Resultados principales

La Tabla 2 concentra la grilla principal de 500 preguntas: tres modelos base, cuatro estrategias comparables online y las métricas de accuracy, costo, latencia y tasa de recuperación.

La tabla muestra tres patrones. Primero, RAG mejora sobre S0 en todos los modelos. S1 aumenta 16.2 puntos en gpt-5-nano, 7.6 en gpt-5-mini y 15.4 en gpt-4.1-mini. Esto confirma que MuSiQue-MC-500 no está saturado por conocimiento paramétrico y que el corpus recuperable aporta información útil.

Segundo, S2 reduce tokens pero paga en accuracy. En gpt-5-mini, usa 1065 tokens frente a 1462 de S1, pero baja de 0.782 a 0.754. La política adaptativa recupera en 40.4 % de los casos; algunos de los casos omitidos probablemente requerían evidencia. El resultado no invalida la adaptatividad: muestra que la política de decisión es tan importante como el generador.

Tercero, S3 maximiza accuracy pero no siempre con un costo justificable. En gpt-5-mini llega a 0.808 con 2296 tokens; en gpt-5-nano, recupera en 99.4 % de los casos y usa 3996 tokens. Para modelos chicos, la política activa puede colapsar en una versión más cara de “recuperar siempre”. Para modelos intermedios, como gpt-5-mini, S3 logra mejor balance porque activa recuperación en una proporción menor.

La comparación entre modelos muestra tres regímenes. En gpt-4.1-mini, el costo es bajo pero el techo de accuracy también; incluso S3 queda en 0.622. En gpt-5-nano, RAG tiene un efecto grande: S0 parte de 0.554 y S3 llega a 0.744, aunque con un costo alto. En gpt-5-mini, el modelo ya resuelve bastante sin contexto, pero todavía gana con memoria externa. Este régimen intermedio es el

más interesante para diseño de sistemas: hay casos donde conviene pagar recuperación y casos donde no.

El resultado de gpt-5-nano con S3 merece atención. Una tasa de recuperación de 0.994 significa que el mecanismo activo casi nunca decide quedarse con la hipótesis inicial. En la práctica, S3 deja de ser selectivo y se acerca a un pipeline fijo más caro: primero piensa, luego recupera casi siempre y finalmente revisa. Esto explica por qué mejora accuracy pero no necesariamente eficiencia. Para modelos chicos, las señales de incertidumbre pueden estar mal calibradas o ser demasiado conservadoras.

En cambio, gpt-5-mini activa recuperación en 0.750 de los casos con S3. Esto indica que el modelo tiene más capacidad para distinguir cuándo su respuesta inicial puede ser suficiente. La mejora de S3 sobre S1 es de 2.6 puntos, pero con 834 tokens adicionales promedio. Dependiendo de la aplicación, ese costo puede ser razonable o no. Por eso reportamos tokens junto con accuracy: el mejor sistema en una tabla de accuracy no siempre es el mejor sistema operativo.

La Figura 1 compacta la relación entre capacidad del modelo, memoria externa y costo. gpt-5-mini domina en accuracy absoluta, pero no siempre en eficiencia. gpt-4.1-mini es barato, aunque con menor techo. gpt-5-nano muestra el caso más interesante: RAG lo vuelve competitivo, pero S3 se vuelve caro porque casi siempre recupera.

También hay una lectura por sistemas. S1 es el baseline más estable: paga contexto siempre y por eso evita errores de routing. S2 es el más sensible a la política: cuando decide no recuperar en preguntas multi-hop que sí requieren evidencia, ahorra tokens pero pierde información. S3 tiene el mayor potencial de corrección, porque permite generar

| Modelo       | Sistema | Accuracy | Tokens | Latencia (s) | Retrieval | $\Delta$ vs S0 |
|--------------|---------|----------|--------|--------------|-----------|----------------|
| gpt-5-nano   | S0      | 0.554    | 1615   | 10.80        | –         | 0.000          |
|              | S1      | 0.716    | 1934   | 7.55         | 1.000     | 0.162          |
|              | S2      | 0.630    | 1420   | 6.67         | 0.404     | 0.076          |
|              | S3      | 0.744    | 3996   | 21.32        | 0.994     | 0.190          |
| gpt-5-mini   | S0      | 0.696    | 993    | 8.70         | –         | 0.000          |
|              | S1      | 0.782    | 1462   | 5.67         | 1.000     | 0.086          |
|              | S2      | 0.754    | 1065   | 6.84         | 0.404     | 0.058          |
|              | S3      | 0.808    | 2296   | 15.18        | 0.750     | 0.112          |
| gpt-4.1-mini | S0      | 0.404    | 350    | 1.28         | –         | 0.000          |
|              | S1      | 0.558    | 995    | 1.25         | 1.000     | 0.154          |
|              | S2      | 0.468    | 529    | 1.35         | 0.404     | 0.064          |
|              | S3      | 0.622    | 1231   | 3.30         | 0.870     | 0.218          |

Tabla 2: Resultados principales sobre MuSiQue-MC-500. S3 obtiene la mayor accuracy individual en los tres modelos, pero aumenta el costo en tokens.




Figura 1: Accuracy vs tokens promedio para S0–S3. El gráfico resume el trade-off principal: S3 suele ganar accuracy, pero desplaza los puntos hacia mayor costo.

| Dataset  | S0    | S1    | S2    | S3    | Tok. S3/S0 |
|----------|-------|-------|-------|-------|------------|
| MuSiQue  | 0.696 | 0.782 | 0.754 | 0.808 | 2.31×      |
| HotpotQA | 0.800 | 0.924 | 0.882 | 0.942 | 2.51×      |
| 2Wiki    | 0.810 | 0.892 | 0.850 | 0.898 | 2.37×      |

Tabla 3: Extensión multi-dataset S0–S3 con gpt-5-mini. Las columnas S0–S3 reportan accuracy; la última columna muestra el costo relativo de S3 frente a S0 en tokens promedio.

una hipótesis y revisarla con evidencia; pero si la evidencia recuperada es distractora, el mismo mecanismo puede reforzar una respuesta equivocada. Esta tensión motiva las corridas de robustez y el uso de S4 como auditor.

Para verificar que el patrón no fuera exclusivo de MuSiQue, replicamos la comparación S0–S3 con gpt-5-mini en HotpotQA-MC-500 y 2Wiki-MC-500. La Tabla 3 muestra que la recuperación mejora sobre S0 en los tres datasets. S3 obtiene la mayor accuracy en todos los casos, pero también es la estrategia más costosa: usa  $2.31\times$ ,  $2.51\times$  y

$2.37\times$  los tokens de S0 en MuSiQue, HotpotQA y 2Wiki. S1 queda como alternativa simple y competitiva, especialmente en 2Wiki, donde obtiene 0.892 frente a 0.898 de S3 con bastante menor costo.

## 6. Routing, auditoría y robustez

S5 evalúa si los sistemas tienen errores complementarios. La Tabla 4 muestra que, en gpt-5-mini, *confidence-then-cost* alcanza 0.814 con 1258 tokens seleccionados, frente a S3 con 0.808 y 2296 tokens. La política elige S3 solo en 76 de 500 casos. Esto sugiere que no hace falta usar siempre la estrategia más compleja: S0, S1 y S2 aciertan subconjuntos que S3 no domina completamente.

El oracle de S5 marca un techo: 0.896 en gpt-5-mini con 967 tokens seleccionados. La brecha entre 0.814 y 0.896 muestra que las heurísticas actuales están lejos de una política ideal, pero también que existe señal explotable. Un router futuro debería estimar antes de ejecutar todos los sistemas qué estrategia conviene usar, por ejemplo con features del recuperador, confianza del modelo directo, acuerdo parcial y costo esperado.

S4 se usa como auditor focalizado sobre 25 casos `s3_wrong_others_correct` de gpt-5-mini. En ese subconjunto, S4 se abstuvo en el 100 % de los casos y rechazó claims insuficientemente sustentados. Este resultado no es una métrica global, porque el subconjunto fue elegido justamente por contener errores de S3. Su valor es cualitativo: muestra que una capa factual puede detectar falta de soporte cuando una estrategia compleja produce una respuesta no respaldada. La tabla agregada de S4 y la grilla completa de desacuerdos se reportan en el Apéndice.

La abstención sistemática de S4 no debe leerse



| Modelo       | Política             | Acc.  | Tokens | Acc./1k tok. | S0  | S1  | S2  | S3 |
|--------------|----------------------|-------|--------|--------------|-----|-----|-----|----|
| gpt-5-mini   | agreement_min_cost   | 0.780 | 876    | 0.890        | 233 | 21  | 237 | 9  |
|              | confidence_then_cost | 0.814 | 1258   | 0.647        | 160 | 107 | 157 | 76 |
|              | risk_aware_s5        | 0.776 | 1057   | 0.734        | 203 | 58  | 196 | 43 |
|              | oracle_min_cost      | 0.896 | 967    | 0.926        | 212 | 45  | 219 | 24 |
| gpt-5-nano   | agreement_min_cost   | 0.708 | 1296   | 0.546        | 184 | 79  | 237 | 0  |
|              | oracle_min_cost      | 0.856 | 1462   | 0.585        | 169 | 92  | 213 | 26 |
| gpt-4.1-mini | confidence_then_cost | 0.560 | 618    | 0.906        | 142 | 82  | 218 | 58 |
|              | oracle_min_cost      | 0.790 | 569    | 1.389        | 144 | 68  | 208 | 80 |

Tabla 4: Resultados seleccionados de S5. Las últimas columnas indican cuántas veces la política elige cada sistema sobre 500 preguntas. S5 es post-hoc: mide complementariedad, no costo online real.

| Condición     | Sistema | Accuracy | Tokens prom. | Retrieve rate | $\Delta$ acc. vs clean |
|---------------|---------|----------|--------------|---------------|------------------------|
| baseline 100q | S0      | 0.72     | 993          | –             | –                      |
| clean         | S1      | 0.81     | 1359         | 1.00          | 0.00                   |
| clean         | S2      | 0.81     | 1098         | 0.60          | 0.00                   |
| clean         | S3-MC   | 0.87     | 2315         | 0.83          | 0.00                   |
| noisy         | S1      | 0.75     | 1351         | 1.00          | -0.06                  |
| noisy         | S2      | 0.74     | 994          | 0.25          | -0.07                  |
| noisy         | S3-MC   | 0.80     | 2247         | 0.75          | -0.07                  |
| adversarial   | S1      | 0.81     | 1351         | 1.00          | 0.00                   |
| adversarial   | S2      | 0.75     | 985          | 0.25          | -0.06                  |
| adversarial   | S3-MC   | 0.79     | 2150         | 0.71          | -0.08                  |

Tabla 5: Robustez con gpt-5-mini sobre 100 preguntas. El baseline S0 corresponde a esas mismas 100 preguntas. S3-MC lidera en clean/noisy, pero S1 es más estable y queda primero en adversarial.

como mejora de accuracy. Un auditor conservador puede ser útil en dominios donde aceptar una respuesta no sustentada es más costoso que no responder, pero puede producir falsos rechazos en tareas donde se espera siempre una opción. En nuestro análisis, S4 cumple otra función: ayuda a explicar por qué S3 falla en algunos casos. Cuando S3 recupera evidencia insuficiente o confusa, el auditor tiende a marcar falta de soporte en lugar de validar la respuesta final.

La Tabla 5 muestra que accuracy máxima y robustez no son equivalentes. S3-MC obtiene 0.87 en clean, pero baja a 0.80 en noisy y 0.79 en adversarial. S1 obtiene 0.81, 0.75 y 0.81. Es decir, la estrategia más compleja gana en corpus limpio, pero su ventaja depende más de la calidad del contexto recuperado. S2 reduce tokens al bajar su retrieval rate de 0.60 a 0.25 en noisy/adversarial, pero esa eficiencia viene acompañada de pérdida de información.

Como esta corrida usa  $n = 100$ , interpretamos diferencias pequeñas con cautela. Una brecha de 2 puntos entre S1 y S3-MC en adversarial está dentro del margen de ruido esperado para una muestra de este tamaño; no la presentamos como prueba con-

cluyente de superioridad, sino como una tendencia que sugiere mayor estabilidad relativa de S1 bajo distractores.

El resultado sostiene una tesis más específica que “RAG mejora”: RAG mejora bajo ciertas condiciones, pero su robustez depende de la política de recuperación. Si el corpus contiene distractores, más contexto no siempre ayuda; puede introducir evidencia parecida pero incorrecta. Por eso, una arquitectura práctica debería combinar selección eficiente, recuperación calibrada y auditoría factual.

La Figura 2 muestra visualmente el cambio de ranking. En clean, S3-MC está claramente arriba. En adversarial, la ventaja desaparece y S1 queda primero. Esto sugiere que la recuperación activa amplifica tanto señales correctas como señales equivocadas. Si recupera evidencia útil, corrige; si recupera evidencia semánticamente cercana pero incorrecta, puede aumentar la confianza en una opción mala.

El análisis de robustez también explica por qué no alcanza con mirar tokens promedio. S2 reduce tokens en noisy/adversarial porque recupera menos, pero esa reducción coincide con caída de ac-




Figura 2: Accuracy bajo corpus limpio, ruidoso y adversarial. S3-MC lidera en clean/noisy, mientras S1 conserva mejor estabilidad relativa en adversarial.

curacy. En otras palabras, ahorrar contexto no es necesariamente mejorar eficiencia: solo es eficiencia si mantiene respuestas correctas. Para que S2 sea competitivo, la política debe distinguir entre evidencia innecesaria y evidencia necesaria pero difícil de recuperar.

## 7. Análisis de costo y errores

El eje de tokens es central porque en un sistema RAG el costo no se concentra solo en la llamada al modelo. Cada decisión de recuperar agrega contexto al prompt, aumenta latencia y expone al generador a información que puede ser útil o distractora. Por eso, dos sistemas con accuracy parecida pueden tener perfiles operativos muy distintos. En gpt-5-mini, S3 mejora apenas 2.6 puntos sobre S1, pero usa 834 tokens más por pregunta. Si el sistema se ejecuta sobre miles de consultas, esa diferencia deja de ser un detalle de implementación y pasa a ser una decisión de producto.

La métrica de accuracy por 1000 tokens ayuda a ver este punto, aunque no debe interpretarse de forma aislada. Un sistema barato puede tener buena eficiencia relativa y, aun así, ser insuficiente si su accuracy absoluta es baja. Esto ocurre con gpt-4.1-mini: S0 es muy barato, pero su 0.404 de accuracy no alcanza para una tarea de respuesta fiable. En cambio, gpt-5-mini permite estudiar un régimen más realista: S0 ya es razonable, S1 mejora con costo moderado, S2 reduce tokens con pérdida controlada y S3 compra accuracy adicional con más contexto.

Una forma de leer los errores es separar preguntas fáciles, recuperables y conflictivas. Las fáciles son aquellas donde S0 ya acierta; allí RAG puede ser redundante. Las recuperables son aquellas

donde S0 falla pero S1 o S3 aciertan; allí la evidencia externa aporta información que el modelo no tenía o no activó. Las conflictivas son las más importantes para diseño de sistemas: el modelo recibe evidencia pero igual falla, o una estrategia compleja falla mientras otra más simple acierta. Estas preguntas muestran que recuperar no garantiza razonar correctamente.

S5 explota precisamente esta heterogeneidad. En la política *confidence-then-cost*, el sistema no elige S3 por defecto: lo reserva para 76 de 500 casos en gpt-5-mini. El resto se reparte entre S0, S1 y S2. Esto indica que las estrategias no forman una escala estricta de calidad, sino un conjunto de especialistas imperfectos. S0 puede acertar por conocimiento paramétrico; S1 puede resolver cuando el top-5 trae evidencia suficiente; S2 puede ser adecuado cuando la recuperación no parece necesaria; S3 puede corregir casos difíciles. La promesa de S5 es combinar esos perfiles.

El problema es que S5, tal como está implementado aquí, es post-hoc. Para decidir necesita observar salidas de varios sistemas, por lo que no ahorra el costo total de ejecución. Esta aclaración es metodológicamente clave: la columna de tokens de S5 reporta el costo de la respuesta seleccionada, no el costo completo de generar todas las candidatas. Por eso S5 no se presenta como arquitectura final, sino como prueba de existencia de señal. Si existe complementariedad post-hoc, entonces tiene sentido entrenar un router online que prediga esa selección antes de ejecutar los sistemas caros.

El análisis de robustez refuerza la misma idea desde otro ángulo. En corpus limpio, S3-MC lidera. En corpus adversarial, S1 resulta más estable. Esto sugiere que la complejidad adicional de S3 depende de la calidad del contexto recuperado. Cuando la recuperación trae evidencia correcta, la hipótesis inicial puede corregirse. Cuando trae distractores semánticamente plausibles, el modelo puede justificar una opción equivocada con aparente soporte. En otras palabras, la recuperación activa no solo amplifica señales buenas; también puede amplificar señales malas.

La diferencia entre *noisy* y *adversarial* es importante. Los distractores aleatorios pueden ocupar espacio en el top- $k$ , pero suelen ser más fáciles de ignorar. Los distractores adversariales compiten semánticamente con la pregunta y pueden parecer evidencia válida. Por eso, la robustez no depende solo de cuántos documentos irrelevantes entran al contexto, sino de cuán cercanos son a la respuesta

correcta. Un sistema de producción rara vez opera sobre un corpus perfectamente limpio; suele convivir con documentos duplicados, contradictorios, viejos o parcialmente relevantes.

S4 aparece como respuesta a ese problema, aunque todavía de forma exploratoria. Si S3 entrega una respuesta incorrecta con evidencia débil, un auditor factual puede detectar que los claims no están suficientemente soportados. Su abstención del 100 % en el subconjunto focalizado no prueba calibración global, pero sí muestra un comportamiento conservador útil para análisis de errores. En dominios de bajo riesgo, abstenerse demasiado puede ser molesto; en dominios de alto riesgo, puede ser preferible a aceptar una respuesta no sustentada.

En conjunto, el patrón de errores sugiere una arquitectura modular. Primero, un componente barato podría intentar responder o estimar dificultad. Segundo, un router decidiría si conviene recuperar y con qué estrategia. Tercero, un auditor se activaría cuando la respuesta depende de evidencia ambigua o cuando hay desacuerdo entre sistemas. Nuestro experimento no implementa todavía ese sistema online completo, pero proporciona evidencia para diseñarlo: los sistemas tienen errores distintos, la recuperación activa no siempre es robusta, y el costo en tokens cambia sustancialmente entre políticas.

## 8. Lectura por hipótesis

Los resultados permiten revisar las hipótesis planteadas al inicio. H1 sostenía que RAG debía mejorar frente a S0 si el benchmark realmente requería evidencia multi-hop. Esta hipótesis se cumple de forma consistente: S1 mejora sobre S0 en los tres modelos. La mejora es mayor cuando el modelo directo parte de más abajo, como ocurre con gpt-4.1-mini y gpt-5-nano. En gpt-5-mini, S0 ya alcanza 0.696, por lo que el margen es menor, pero S1 igualmente llega a 0.782. La extensión multi-dataset refuerza la lectura: con gpt-5-mini, S1 supera a S0 en MuSiQue, HotpotQA y 2Wiki. Esto confirma que la evidencia externa aporta información útil, aunque la magnitud de la ganancia cambia según el benchmark.

H2 proponía que la recuperación activa mejoraría accuracy a costa de tokens. También se confirma. S3 es el mejor sistema individual para los tres modelos y también para los tres datasets MC-500 con gpt-5-mini, pero nunca es el más barato. El caso extremo es gpt-5-nano: S3 alcanza 0.744, pero usa 3996 tokens promedio y recupera en 99.4 % de

los casos. La conclusión es que S3 funciona, pero su valor depende de la calibración de la señal que decide recuperar y del costo marginal frente a S1.

H3 afirmaba que la adaptatividad podía ahorrar tokens, pero dependía de la política. S2 confirma esa tensión. En todos los modelos reduce tokens respecto de S1; sin embargo, queda por debajo de S1 en accuracy. El mismo patrón aparece en HotpotQA y 2Wiki: S2 mejora sobre S0, pero no captura todos los casos donde recuperar evidencia fija era útil. En preguntas multi-hop, una consulta puede parecer familiar y aun así requerir encadenar hechos.

H4 sostenía que existiría complementariedad entre sistemas. S5 aporta la evidencia principal. Si S3 dominara estrictamente a todos los demás sistemas, un meta-router no podría igualarlo o superarlo seleccionando a veces S0, S1 o S2. Sin embargo, *confidence-then-cost* elige S3 solo en 76 de 500 casos y alcanza 0.814. El oracle de mínimo costo llega a 0.896. La brecha entre ambos números muestra que la señal actual es imperfecta, pero la complementariedad existe. Esta es una de las conclusiones más importantes del trabajo: la mejora futura probablemente no venga solo de hacer un RAG más complejo, sino de aprender cuándo usar cada estrategia.

La robustez agrega una quinta lectura, no planteada inicialmente como hipótesis central pero relevante para aplicaciones reales. Un sistema puede ser el mejor en clean y no ser el más robusto. S3-MC lidera en corpus limpio, pero cae ante distractores; S1, más simple, conserva mejor estabilidad adversarial. Esto sugiere que las evaluaciones RAG deberían reportar no solo accuracy en corpus limpio, sino también sensibilidad a ruido, porque los corpus reales rara vez son perfectamente curados.

## 9. Implicancias metodológicas y validez

El formato multiple-choice fue útil para aislar una métrica clara, pero obliga a ser cuidadosos. Si las opciones contienen pistas superficiales, la accuracy puede medir explotación de artefactos en lugar de razonamiento. Por eso la auditoría del dataset no es un detalle menor: forma parte del diseño experimental. Balancear A/B/C/D, eliminar booleanas mal construidas y controlar longitud de opciones reduce la probabilidad de que todos los sistemas parezcan mejores por razones equivocadas.

También es importante distinguir entre evaluación de respuesta y evaluación de evidencia. S0-S3



eligen una opción; S4 evalúa soporte. Es tentador comparar todo con una única métrica de accuracy, pero eso mezclaría objetivos distintos. Un auditor puede abstenerse correctamente cuando la evidencia no alcanza, incluso si la opción correcta existe. En este trabajo, S4 se interpreta como una herramienta de análisis y control de riesgo, no como otro competidor en la misma tabla.

La separación entre costo seleccionado y costo real también es metodológicamente importante. En S5, los tokens reportados corresponden al sistema elegido, no al costo de producir todas las respuestas que S5 observa. Esta decisión permite medir la frontera potencial de selección, pero no debe confundirse con el costo online. Para que S5 sea deployable, habría que reemplazarlo por un router predictivo que decida antes de ejecutar todos los candidatos. Esta distinción evita sobreinterpretar el 81.4 % como una mejora productiva ya disponible.

Otra decisión fue reportar modelos de diferente capacidad en lugar de un único tamaño. Esto permite ver que el valor de RAG no es constante. Modelos chicos pueden beneficiarse más de evidencia externa, pero también pueden usar peor señales de incertidumbre y recuperar casi siempre. Modelos más capaces pueden responder más casos directamente, pero también aprovechar mejor evidencia cuando se les da. Por eso, una conclusión sobre “RAG mejora” siempre debería especificar para qué modelo, qué corpus y qué política de recuperación.

La extensión a HotpotQA-MC-500 y 2Wiki-MC-500 mejora la validez externa del trabajo, pero no elimina diferencias entre benchmarks. Los tres fueron convertidos al mismo formato y evaluados con el mismo modelo y las mismas estrategias, aunque difieren en estilo de pregunta, distribución de entidades, dificultad y grado de saturación del baseline directo. Por eso, los resultados multi-dataset deben leerse como evidencia de consistencia del patrón general, no como prueba de dificultad experimental idéntica.

Finalmente, la robustez muestra que la evaluación en corpus limpio puede ser optimista. Si un pipeline se despliega sobre una base documental real, encontrará duplicados, textos parciales, documentos viejos, entidades ambiguas y distractores semánticos. Nuestro experimento de ruido es controlado y pequeño, pero apunta a ese problema. La caída de S3-MC en adversarial sugiere que un sistema más sofisticado puede ser más vulnerable si su mecanismo de revisión confía demasiado en evidencia recuperada.

Estas implicancias orientan el uso práctico de los resultados. Para un sistema barato y estable, S1 puede ser una opción razonable. Para maximizar accuracy en un benchmark limpio, S3 es preferible. Para estudiar eficiencia futura, S5 muestra el camino, pero todavía requiere convertir la selección post-hoc en routing online. Para tareas donde la factualidad importa, S4 puede funcionar como capa de abstención o revisión. El punto no es elegir un único ganador, sino entender qué pieza cumple cada rol.

La validez del experimento depende de que todos los sistemas comparen sobre una misma superficie. Por eso, S0–S3 usan las mismas 500 preguntas, las mismas opciones y, cuando corresponde, el mismo corpus recuperable. Esta decisión evita una fuente común de confusión en evaluaciones RAG: atribuir a la arquitectura diferencias que en realidad provienen de prompts, documentos o subconjuntos distintos. En nuestro caso, lo que cambia entre S0, S1, S2 y S3 es la política de uso de evidencia.

Otra decisión de validez fue separar saturación de evaluación principal. Antes de correr todos los sistemas, se midió S0 sobre varios benchmarks. Esto permitió descartar datasets donde el modelo directo ya resolvía demasiado. Si el benchmark está saturado, RAG puede parecer innecesario; si es excesivamente difícil, RAG puede parecer insuficiente aunque la arquitectura sea razonable. MuSiQue-MC-500 queda en un punto intermedio: S0 no colapsa, pero tampoco resuelve todo. Ese rango permite observar mejoras y costos.

También se controló la distribución de respuestas correctas. En multiple-choice, un sesgo de posición puede contaminar la accuracy: un modelo con preferencia por C podría parecer mejor si C aparece de forma desproporcionada. Balancear A/B/C/D no garantiza eliminar todos los sesgos, pero reduce un atajo obvio. Del mismo modo, auditar longitud y tipo semántico de opciones reduce la posibilidad de que el modelo descarte distractores por forma y no por contenido.

La evaluación de robustez tiene menor escala que la grilla principal y debe interpretarse como experimento controlado, no como resultado definitivo. Su valor está en mostrar sensibilidad: al modificar el corpus recuperable, cambia el ranking de sistemas. Esa señal justifica evaluar RAG no solo en datasets limpios, sino también bajo condiciones donde la recuperación trae evidencia parcial, redundante o adversarial. Para una versión futura, el mismo protocolo debería ampliarse a las 500 preguntas y a

los tres modelos.

Finalmente, el trabajo distingue entre resultados deployables y resultados diagnósticos. S0–S3 son sistemas ejecutables pregunta por pregunta. S5, en cambio, es una medición post-hoc de complementariedad. S4 es una auditoría focalizada. Esta separación hace que el informe sea más conservador: no presenta S5 como producto final ni S4 como métrica global, sino como herramientas para entender dónde hay margen de mejora.

## 10. Discusión, limitaciones y trabajo futuro

Los resultados sugieren tres lecciones. Primero, RAG fijo es un baseline fuerte y estable: S1 mejora sobre S0 en todos los modelos y resiste mejor la condición adversarial. Segundo, la adaptatividad ahorra tokens, pero solo es útil si la política distingue bien preguntas que requieren evidencia. Tercero, la recuperación activa maximiza accuracy en limpio, pero puede volverse cara o frágil ante ruido.

El tamaño del modelo cambia el valor de la memoria. En gpt-5-mini, S0 ya es fuerte y RAG aporta mejoras moderadas. En gpt-5-nano, RAG compensa más conocimiento faltante, aunque S3 activa recuperación casi siempre. En gpt-4.1-mini, el costo es bajo pero el techo de accuracy también. Por lo tanto, no hay un único pipeline ganador: la estrategia depende del modelo, del costo permitido y de la confiabilidad del corpus.

S5 no debe presentarse como una solución online terminada. Es post-hoc y requiere haber corrido S0–S3; por eso su costo real de producción sería mayor que el costo de la respuesta seleccionada. Aun así, es útil porque demuestra complementariedad. Si un router predictivo pudiera anticipar qué sistema conviene antes de ejecutarlos todos, podría acercarse a una mejor frontera accuracy/tokens.

La implicación práctica es que una arquitectura RAG debería tratar la recuperación como una decisión de control y no como una plantilla fija. Para consultas simples, responder directo puede ser suficiente. Para consultas multi-hop con evidencia clara, RAG fijo funciona bien. Para consultas difíciles, recuperación activa puede corregir errores. Para respuestas de alto riesgo, una capa de auditoría puede abstenerse si no hay soporte suficiente. El desafío futuro es aprender esa política antes de pagar todos los costos.

### Limitaciones.

- El benchmark es multiple-choice; esto permite accuracy exacta, pero puede ocultar dificultades de respuesta abierta.
- MuSiQue-MC-500 fue auditado, aunque pueden quedar sesgos residuales de estilo, longitud o semántica.
- La extensión multi-dataset usa solo gpt-5-mini y solo S0–S3; S4, S5 y robustez siguen centrados en MuSiQue.
- La robustez se evaluó sobre 100 preguntas y solo con gpt-5-mini; falta extenderla a más modelos.
- S4 se corrió en subconjuntos focalizados; sirve para análisis de errores, no para estimar accuracy global.
- S5 es post-hoc; mide margen para routing, no un sistema deployable.

### Trabajo futuro.

- Entrenar un router online que elija S0/S1/S2/S3 antes de pagar todos los costos.
- Extender robustez, S4 y S5 a más modelos, más preguntas y otros datasets MC-500.
- Evaluar respuesta abierta con exact match, F1, evaluación semántica y verificación factual.
- Calibrar S4 para reducir falsos rechazos y decidir cuándo abstenerse.
- Estudiar recuperación bajo corpus reales con documentos contradictorios o parcialmente irrelevantes.

## 11. Conclusión

Evaluamos estrategias RAG adaptativas sobre MuSiQue-MC-500. La recuperación externa mejora el rendimiento en preguntas multi-hop, pero cada estrategia tiene un perfil distinto. S1 es simple y estable; S2 ahorra tokens pero depende fuertemente de la política; S3 maximiza accuracy individual a mayor costo; S4 aporta auditoría factual; y S5 muestra que los errores de los sistemas son complementarios.

En particular, S5 y S4 constituyen el aporte de diseño propio de este trabajo por sobre la adaptación de S0–S3: S5 cuantifica complementariedad entre estrategias y S4 aplica auditoría factual selectiva sobre errores de S3.

La extensión a HotpotQA-MC-500 y 2Wiki-MC-500 refuerza esta lectura: en los tres datasets, las

estrategias con recuperación superan al baseline directo y S3 logra la mayor accuracy. Sin embargo, el costo adicional de S3 y la cercanía de S1 en algunos casos muestran que el problema no se reduce a elegir el sistema más complejo, sino a seleccionar la estrategia adecuada para cada régimen de dificultad y presupuesto.

El hallazgo central es que no alcanza con preguntar si conviene usar RAG. La decisión relevante es cuándo recuperar, cuánto contexto pagar, qué sistema ejecutar y cuándo auditar la evidencia. En escenarios limpios, S3 puede ser la mejor estrategia individual. En escenarios ruidosos, S1 puede ser más robusto. Y en análisis post-hoc, S5 muestra que una política de selección puede mejorar el balance entre accuracy y tokens. El próximo paso es convertir esa señal en un router predictivo real y evaluarlo en condiciones de ruido más amplias.

## References

- Akari Asai, Zeqiu Wu, Yizhong Wang, Avirup Sil, and Hannaneh Hajishirzi. 2024. Self-rag: Learning to retrieve, generate, and critique through self-reflection. In *International Conference on Learning Representations*.
- Tianyu Gao, Howard Yen, Jiatong Yu, and Danqi Chen. 2023. Enabling large language models to generate text with citations. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*.
- Kelvin Guu, Kenton Lee, Zora Tung, Panupong Pasupat, and Ming-Wei Chang. 2020. Realm: Retrieval-augmented language model pre-training. In *Proceedings of the 37th International Conference on Machine Learning*.
- Xanh Ho, Anh-Khoa Duong Nguyen, Saku Sugawara, and Akiko Aizawa. 2020. Constructing a multi-hop qa dataset for comprehensive evaluation of reasoning steps. In *Proceedings of the 28th International Conference on Computational Linguistics*.
- Gautier Izacard, Patrick Lewis, Maria Lomeli, Lucas Hosseini, Fabio Petroni, Timo Schick, Jane Dwivedi-Yu, Armand Joulin, Sebastian Riedel, and Edouard Grave. 2023. Atlas: Few-shot learning with retrieval augmented language models. *Journal of Machine Learning Research*.
- Zhengbao Jiang, Frank F. Xu, Luyu Gao, Zhiqing Sun, Qian Liu, Jane Dwivedi-Yu, Yiming Yang, Jamie Callan, and Graham Neubig. 2023. Active retrieval augmented generation. *arXiv preprint arXiv:2305.06983*.
- Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. 2020. Retrieval-augmented generation for knowledge-intensive nlp tasks. In *Advances in Neural Information Processing Systems*.
- James Thorne, Andreas Vlachos, Christos Christodoulopoulos, and Arpit Mittal. 2018. Fever: a large-scale dataset for fact extraction and verification. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics*.
- Harsh Trivedi, Niranjan Balasubramanian, Tushar Khot, and Ashish Sabharwal. 2022. Musique: Multihop questions via single-hop question composition. In *Transactions of the Association for Computational Linguistics*.
- Zhilin Yang, Peng Qi, Saizheng Zhang, Yoshua Bengio, William W. Cohen, Ruslan Salakhutdinov, and Christopher D. Manning. 2018. Hotpotqa: A dataset for diverse, explainable multi-hop question answering. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*.

## A. Material suplementario

| Benchmark   | Modelo   | $n$ | Acc. S0 | Interpretación                             |
|-------------|----------|-----|---------|--------------------------------------------|
| 2Wiki       | 4.1-mini | 100 | 0.61    | Dificultad media para el modelo más débil. |
| 2Wiki       | 5-mini   | 100 | 0.82    | Saturado para el modelo más fuerte.        |
| 2Wiki       | 5-nano   | 100 | 0.57    | No saturado.                               |
| HotpotQA    | 4.1-mini | 100 | 0.62    | Dificultad media.                          |
| HotpotQA    | 5-mini   | 100 | 0.79    | Cercano al umbral de saturación.           |
| HotpotQA    | 5-nano   | 100 | 0.71    | Moderado.                                  |
| MultiHopRAG | 4.1-mini | 100 | 0.85    | Saturado.                                  |
| MultiHopRAG | 5-mini   | 100 | 0.88    | Saturado.                                  |
| MultiHopRAG | 5-nano   | 100 | 0.85    | Saturado.                                  |
| MuSiQue     | 4.1-mini | 100 | 0.44    | Adecuado para medir recuperación.          |
| MuSiQue     | 5-mini   | 100 | 0.69    | No saturado.                               |
| MuSiQue     | 5-nano   | 100 | 0.66    | No saturado.                               |

Tabla 6: Chequeo de saturación con S0 directo sobre benchmarks multiple-choice.




Figura 3: Accuracy por modelo y sistema.




Figura 4: Costo promedio por pregunta.

| Caso               | 4.1 | 5m  | 5n  |
|--------------------|-----|-----|-----|
| all agree correct  | 124 | 302 | 215 |
| all agree wrong    | 48  | 31  | 30  |
| all wrong disag.   | 57  | 21  | 42  |
| mixed correctness  | 147 | 89  | 132 |
| s3 only correct    | 40  | 13  | 26  |
| s3 wrong/others ok | 84  | 44  | 55  |

Tabla 7: Desacuerdos entre S0-S3.

| S4 focalizado  | Valor |
|----------------|-------|
| Casos          | 25    |
| Error rate     | 0.000 |
| Abstention     | 1.000 |
| Correction     | 1.000 |
| Claims prom.   | 2.000 |
| Claims soport. | 0.120 |
| Claims refut.  | 0.120 |
| Claims NEI     | 1.760 |
| Rondas         | 3.800 |
| Chunks         | 3.440 |

Tabla 8: S4 sobre casos s3\_wrong.




Figura 5: Decisiones S5 para gpt-5-mini.