

Estrategias RAG Adaptativas para Razonamiento Multi-hop

Camila Di Paola Felipe Andrés Sidiropulos Lamouret Alan Schadan

Victoria Lescano Charreau Ion Harteker

Universidad de San Andrés

{cdipaola, fsidiropuloslamouret, aschadan, llescano, iharteker}@udes.edu.ar

Resumen

Evalúamos cuándo conviene responder directamente con un modelo de lenguaje y cuándo conviene agregar recuperación externa en preguntas multi-hop. Construimos MuSiQue-MC-500, una versión multiple-choice y auditable de MuSiQue con corpus recuperable, y comparamos cuatro estrategias online: S0, respuesta directa; S1, RAG fijo top-5; S2, RAG adaptativo; y S3, recuperación activa tipo FLARE. Además analizamos S4, un auditor factual focalizado, y S5, un meta-router post-hoc que selecciona entre salidas ya generadas. Sobre 500 preguntas, S3 logra la mayor accuracy individual en los tres modelos compactos evaluados; con gpt-5-mini alcanza 80.8 % con 2296 tokens promedio. La comparación se extiende a HotpotQA-MC-500 y 2Wiki-MC-500, donde la recuperación también supera al baseline directo. S5 alcanza 81.4 % usando menos tokens seleccionados que S3, aunque no es deployable por ser post-hoc. Concluimos que RAG no es una decisión binaria: la pregunta central es cuándo recuperar, cuánto contexto pagar y cuándo auditar evidencia.

1. Introducción

Las preguntas multi-hop requieren combinar varios hechos para llegar a una respuesta. Un modelo de lenguaje puede fallar en este escenario por memoria incompleta, confusión de entidades o razonamiento parcial. Retrieval-Augmented Generation (RAG) (Lewis et al., 2020) aborda este problema incorporando documentos externos en tiempo de inferencia, pero recuperar evidencia no es gratis: aumenta tokens, latencia y exposición a contexto irrelevante.

Este trabajo pregunta qué se gana y qué se pierde al pasar de un LLM directo a estrategias RAG fijas, adaptativas y activas. La hipótesis es que no existe una estrategia universalmente dominante. Algunas preguntas pueden resolverse con conocimiento paramétrico; otras necesitan evidencia; y otras requie-

ren recuperar, revisar y eventualmente auditar la respuesta.

Nuestras contribuciones son: (i) una evaluación homogénea sobre MuSiQue-MC-500, con 500 preguntas multiple-choice y corpus recuperable; (ii) una comparación de S0–S3 en tres modelos compactos; (iii) una extensión multi-dataset con HotpotQA-MC-500 y 2Wiki-MC-500; (iv) un análisis de robustez bajo corpus limpio, ruidoso y adversarial; y (v) dos extensiones diagnósticas: S4 como auditor factual y S5 como meta-router post-hoc.

2. Trabajo Relacionado

RAG combina recuperación y generación para tareas intensivas en conocimiento (Lewis et al., 2020). REALM (Gua et al., 2020), Atlas (Izacard et al., 2023) y ALCE (Gao et al., 2023) muestran que la memoria externa puede mejorar respuestas y atribución, pero también que la calidad de la evidencia condiciona el resultado. Las preguntas multi-hop fueron estudiadas en HotpotQA (Yang et al., 2018), 2WikiMultiHopQA (Ho et al., 2020) y MuSiQue (Trivedi et al., 2022). Elegimos MuSiQue porque sus preguntas se construyen por composición de pasos simples, lo que reduce la posibilidad de resolverlas por coincidencia superficial.

La recuperación adaptativa y activa intenta evitar que RAG sea una operación fija. FLARE (Jiang et al., 2023) genera primero, estima incertidumbre y recupera cuando hace falta; Self-RAG (Asai et al., 2024) incorpora señales de reflexión para recuperar y criticar. Nuestro trabajo no entrena un modelo nuevo, sino que compara políticas implementables sobre una misma superficie experimental. La auditoría factual se relaciona con FEVER (Thorne et al., 2018): S4 no busca responder mejor, sino decidir si una respuesta está soportada, refutada o insuficientemente respaldada.

3. Benchmark y Sistemas

Dataset. Construimos MuSiQue-MC-500 a partir de MuSiQue, con 500 preguntas multiple-choice, opciones A/B/C/D balanceadas y un corpus recuperable de aproximadamente 6000 documentos. Antes de fijar el benchmark, medimos saturación con S0 sobre candidatos como 2Wiki, HotpotQA, MultiHopRAG y MuSiQue. MuSiQue fue elegido porque S0 no quedaba ni saturado ni colapsado, lo que permite observar mejoras de recuperación.

El formato multiple-choice permite evaluar con accuracy exacta y auditable. Esta decisión reduce ruido de evaluación frente a respuesta abierta, aunque limita el alcance del benchmark. Por eso, respuesta abierta queda como trabajo futuro.

Modelos. Evaluamos modelos compactos y costo-eficientes disponibles al momento de la corrida: gpt-5-nano, gpt-5-mini y gpt-4.1-mini. El objetivo no es comparar contra el último frontier model, sino estudiar cómo cambia el valor de RAG según capacidad y costo.

Sistemas. La Tabla 1 resume los sistemas. S0 responde sin documentos; S1 siempre recupera top-5; S2 recupera solo si una señal del recuperador activa la política; S3 genera una hipótesis inicial, estima incertidumbre y recupera evidencia para revisar. S4 audita respuestas de S3 en casos conflictivos, y S5 elige post-hoc entre salidas S0–S3.

4. Resultados Principales

La Tabla 2 muestra tres patrones. Primero, S1 mejora consistentemente sobre S0: recuperar evidencia siempre es un baseline fuerte para preguntas multi-hop. Segundo, S2 reduce tokens pero pierde accuracy frente a S1, porque algunos casos omitidos sí requerían evidencia. Tercero, S3 maximiza accuracy en los tres modelos, aunque con mayor costo.

El tamaño del modelo cambia el margen de mejora. Los modelos más débiles ganan más con RAG: gpt-4.1-mini pasa de 0.404 a 0.622 con S3. En gpt-5-mini, S0 ya alcanza 0.696, por lo que el margen es menor, aunque S3 llega a 0.808. Para gpt-5-nano, S3 recupera casi siempre, lo que sugiere que una política activa puede colapsar en una versión cara de “recuperar siempre” cuando el modelo calibra peor su incertidumbre.




Figura 1: Trade-off entre accuracy y tokens promedio para S0–S3.

5. Generalización, Routing y Robustez

La Tabla 3 confirma que la mejora de RAG no es exclusiva de MuSiQue. Con gpt-5-mini, S1–S3 superan S0 en los tres benchmarks, y S3 lidera en accuracy. La magnitud cambia: HotpotQA muestra mayor ganancia absoluta, mientras que 2Wiki queda más cerca entre S1 y S3. Esto refuerza la hipótesis de que la estrategia óptima depende del benchmark y del costo tolerado.

S5: confidence-then-cost. S5 evalúa complementariedad entre sistemas. Como ve las salidas ya generadas por S0–S3, no es deployable como política online. Sin embargo, muestra un techo útil: en gpt-5-mini, la regla *confidence-then-cost* alcanza 0.814 con 1258 tokens seleccionados, frente a S3 con 0.808 y 2296 tokens. La lectura correcta no es que S5 sea un sistema final, sino que no siempre hace falta pagar S3: S0, S1 y S2 aciertan subconjuntos que S3 no domina por completo.

S4: auditor factual. S4 revisa respuestas de S3 y chequea si están respaldadas por evidencia. En el subconjunto focalizado de 25 casos conflictivos fue demasiado conservador: se abstuvo en todos los casos. Por eso no lo reportamos como sistema principal de accuracy. Su valor es diagnóstico: muestra cómo una capa de auditoría podría controlar riesgo factual, pero también que la calibración de abstención es un problema abierto.

La robustez fue evaluada en una corrida separada de 100 preguntas con corpus limpio, ruidoso y adversarial. La Tabla 4 no debe compararse directamente con la grilla de 500 preguntas. Dentro de este experimento, S3-MC lidera en clean y noisy, pero cae en adversarial. La explicación es que S3 usa la evidencia de forma más activa para revisar su hipótesis: si recupera evidencia útil, corrige; si recupera distractores semánticamente cercanos, puede refor-

Sistema	Recuperación	Rol experimental
S0	Nunca	Baseline directo sin memoria externa.
S1	Siempre top-5	RAG fijo, simple y estable.
S2	Condicional	Ahorra tokens, pero depende de una buena política.
S3	Activa	Hipótesis inicial, incertidumbre y revisión con evidencia.
S4	Auditoría	Revisa soporte factual de respuestas de S3; exploratorio.
S5	No recupera	Router post-hoc entre salidas ya generadas.

Tabla 1: Sistemas evaluados. S0–S3 son comparables online; S4 y S5 son extensiones diagnósticas.

Modelo	Sistema	Acc.	Tokens	Lat. (s)	Retrieval	Δ vs S0
gpt-5-nano	S0	0.554	1615	10.80	–	0.000
	S1	0.716	1934	7.55	1.000	0.162
	S2	0.630	1420	6.67	0.404	0.076
	S3	0.744	3996	21.32	0.994	0.190
gpt-5-mini	S0	0.696	993	8.70	–	0.000
	S1	0.782	1462	5.67	1.000	0.086
	S2	0.754	1065	6.84	0.404	0.058
	S3	0.808	2296	15.18	0.750	0.112
gpt-4.1-mini	S0	0.404	350	1.28	–	0.000
	S1	0.558	995	1.25	1.000	0.154
	S2	0.468	529	1.35	0.404	0.064
	S3	0.622	1231	3.30	0.870	0.218

Tabla 2: Resultados principales sobre MuSiQue-MC-500. S3 obtiene la mayor accuracy individual, pero paga mayor costo en tokens.

Dataset	S0	S1	S2	S3
MuSiQue	0.696	0.782	0.754	0.808
HotpotQA	0.800	0.924	0.882	0.942
2Wiki	0.810	0.892	0.850	0.898

Tabla 3: Extensión multi-dataset con gpt-5-mini.

Sistema	Clean	Noisy	Adv.
S1	0.81	0.75	0.81
S2	0.81	0.74	0.75
S3-MC	0.87	0.80	0.79

Tabla 4: Robustez sobre 100 preguntas de MuSiQue con gpt-5-mini. S3 lidera en clean/noisy, pero pierde estabilidad relativa en adversarial.

zar una respuesta equivocada. S1 también puede verse afectado, pero al tener una interacción más simple con la evidencia amplifica menos el ciclo de revisión.

6. Discusión

Los resultados apoyan una lectura no binaria de RAG. S1 es fuerte y estable porque siempre provee contexto, pero paga tokens aun cuando no hacen falta. S2 intenta ahorrar, aunque su rendimiento depende de decidir bien cuándo recuperar. S3 obtiene la mejor accuracy individual, pero puede ser caro

y más sensible a evidencia adversarial. S4 y S5 muestran dos direcciones complementarias: auditar respuestas y rutear estrategias.

El diseño multiple-choice fue útil para comparar muchos sistemas con una métrica exacta. También permitió auditar balance de opciones y reducir artefactos de formato. Aun así, no reemplaza evaluación de respuesta abierta. Del mismo modo, la extensión multi-dataset mejora la validez externa, pero no implica que MuSiQue, HotpotQA y 2Wiki tengan la misma dificultad: difieren en estilo de pregunta, distribución de entidades y saturación del baseline directo.

Una arquitectura práctica debería tratar la recuperación como una decisión de control. Para consultas simples, S0 puede alcanzar; para consultas con evidencia clara, S1 es una baseline robusta; para casos difíciles, S3 puede corregir hipótesis; y para respuestas de alto riesgo, una auditoría puede abstenerse si no hay soporte suficiente. El próximo paso natural es entrenar un router online que decida antes de ejecutar qué estrategia usar.

7. Conclusión

Evaluamos estrategias RAG adaptativas sobre MuSiQue-MC-500. La recuperación externa mejora el rendimiento en preguntas multi-hop, pero

cada estrategia tiene un perfil distinto: S1 es estable, S2 ahorra tokens, S3 maximiza accuracy, S4 audita evidencia y S5 muestra complementariedad. La extensión a HotpotQA-MC-500 y 2Wiki-MC-500 confirma que el patrón general se mantiene con gpt-5-mini. El hallazgo central es que la pregunta relevante no es si usar RAG, sino cuándo recuperar, cuánto contexto pagar, qué sistema ejecutar y cuándo auditar evidencia.

Limitaciones

El benchmark principal es multiple-choice, lo que facilita evaluación exacta pero puede ocultar dificultades de generación abierta. La robustez se midió sobre 100 preguntas y solo con gpt-5-mini; falta extenderla a más modelos y al conjunto completo. S4 fue focalizado y conservador, por lo que no estima accuracy global. S5 es post-hoc y mide potencial de routing, no un sistema deployable. Finalmente, aunque MuSiQue-MC-500 fue auditado, pueden persistir sesgos residuales de estilo, longitud o semántica de opciones.

Trabajo Futuro

El trabajo futuro inmediato es entrenar un router online que elija S0/S1/S2/S3 antes de pagar todos los costos. También corresponde evaluar respuesta abierta con exact match, F1 y verificación factual; ampliar robustez a más datasets y modelos; y calibrar S4 para reducir falsos rechazos. En escenarios reales, la recuperación debería evaluarse con documentos contradictorios, duplicados, incompletos o parcialmente irrelevantes.

References

- Akari Asai, Zeqiu Wu, Yizhong Wang, Avirup Sil, and Hannaneh Hajishirzi. 2024. Self-rag: Learning to retrieve, generate, and critique through self-reflection. In *International Conference on Learning Representations*.
- Tianyu Gao, Howard Yen, Jiatong Yu, and Danqi Chen. 2023. Enabling large language models to generate text with citations. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*.
- Kelvin Guu, Kenton Lee, Zora Tung, Panupong Pasupat, and Ming-Wei Chang. 2020. Realm: Retrieval-augmented language model pre-training. In *Proceedings of the 37th International Conference on Machine Learning*.
- Xanh Ho, Anh-Khoa Duong Nguyen, Saku Sugawara, and Akiko Aizawa. 2020. Constructing a multi-hop qa dataset for comprehensive evaluation of reasoning steps. In *Proceedings of the 28th International Conference on Computational Linguistics*.
- Gautier Izacard, Patrick Lewis, Maria Lomeli, Lucas Hosseini, Fabio Petroni, Timo Schick, Jane Dwivedi-Yu, Armand Joulin, Sebastian Riedel, and Edouard Grave. 2023. Atlas: Few-shot learning with retrieval augmented language models. *Journal of Machine Learning Research*.
- Zhengbao Jiang, Frank F. Xu, Luyu Gao, Zhiqing Sun, Qian Liu, Jane Dwivedi-Yu, Yiming Yang, Jamie Callan, and Graham Neubig. 2023. Active retrieval augmented generation. *arXiv preprint arXiv:2305.06983*.
- Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. 2020. Retrieval-augmented generation for knowledge-intensive nlp tasks. In *Advances in Neural Information Processing Systems*.
- James Thorne, Andreas Vlachos, Christos Christodoulopoulos, and Arpit Mittal. 2018. Fever: a large-scale dataset for fact extraction and verification. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics*.
- Harsh Trivedi, Niranjan Balasubramanian, Tushar Khot, and Ashish Sabharwal. 2022. Musique: Multihop questions via single-hop question composition. In *Transactions of the Association for Computational Linguistics*.
- Zhilin Yang, Peng Qi, Saizheng Zhang, Yoshua Bengio, William W. Cohen, Ruslan Salakhutdinov, and Christopher D. Manning. 2018. Hotpotqa: A dataset for diverse, explainable multi-hop question answering. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*.