

ESTRATEGIAS RAG ADAPTATIVAS PARA RAZONAMIENTO MULTI-HOP



Camila Di Paola
cdipaola@udesa.edu.ar

Felipe Andrés Sidiropulos Lamouret
fsidiropuloslamouret@udesa.edu.ar

Alan Schadan
aschadane@udesa.edu.ar

Victoria Lescano Charreau
llescano@udesa.edu.ar

Ion Harteker
iharteker@udesa.edu.ar

MOTIVACIÓN

Los modelos de lenguaje pueden fallar en preguntas multi-hop porque necesitan combinar varios hechos, y ahí surgen errores de memoria incompleta o confusión de entidades. RAG agrega recuperación externa para resolver esto, pero no es gratis: aumenta tokens, latencia y expone al modelo a contexto irrelevante o engañoso. La pregunta central del trabajo es **qué se gana y qué se pierde al pasar de un LLM directo a estrategias RAG fijas, adaptativas y activas, partiendo de la hipótesis de que ninguna estrategia domina en todos los casos.**

DATASET Y PREPROCESAMIENTO

Se construyó MuSiQue-MC-500, una versión multiple-choice y auditable de MuSiQue con 500 preguntas y corpus recuperable de 6000 documentos, elegida como benchmark principal por su dificultad adecuada para medir el aporte de RAG. Luego, para evaluar si las conclusiones generalizaban más allá de MuSiQue, se extendió la comparación S0-S3 a HotpotQA-MC-500 y 2Wiki-MC-500 usando el mismo modelo base. Los datasets fueron auditados para balancear la posición correcta entre A/B/C/D y reducir artefactos de formato, como distractores truncados, booleanas mal construidas u opciones semánticamente incompatibles, evitando que la accuracy mida atajos superficiales en vez de razonamiento multi-hop.




Figura: Chequeo de saturación con S0 (accuracy directa, sin RAG) sobre cuatro benchmarks candidatos. Solo MuSiQue queda por debajo del umbral de saturación (80%), por lo que se eligió para construir MuSiQue-MC-500.

METODOLOGÍA

Se evaluaron seis sistemas sobre tres modelos base, midiendo accuracy, tokens, latencia y tasa de recuperación. Además de la grilla principal de 500 preguntas, se corrió una evaluación de robustez con 100 preguntas en tres condiciones: corpus limpio, con ruido aleatorio y con distractores adversariales.

- **Gpt-5-nano** – bajo costo, menor capacidad
- **Gpt-5-mini** – foco principal del análisis
- **Gpt-4.1-mini** – baseline de referencia

SISTEMAS EVALUADOS

El sistema funciona en capas, desde responder directo hasta recuperar y auditar evidencia de forma activa:

- **S0 – LLM directo:** responde solo con conocimiento paramétrico, sin recuperar nada. Es el baseline.
- **S1 – RAG fijo:** recupera siempre un top-5 de documentos antes de responder.
- **S2 – RAG adaptativo:** recupera solo si una señal del recuperador indica que el caso lo necesita.
- **S3 – Recuperación activa (FLARE-like):** genera una hipótesis inicial, estima su incertidumbre y recupera evidencia para revisarla si hace falta.
- **S4 – Auditor factual:** revisa selectivamente casos conflictivos de S3, chequeando si los claims tienen soporte en la evidencia.
- **S5 – Meta-router post-hoc:** no recupera nada; elige, entre las salidas ya generadas por S0-S3, cuál conviene usar.




Diagrama: los seis sistemas evaluados, desde respuesta directa (S0) hasta selección post-hoc entre estrategias (S5).

RESULTADOS

S3 obtiene la mayor accuracy individual en los tres modelos, pero también el mayor costo en tokens: en gpt-5-mini llega a 80.8% con 2296 tokens promedio. S1 mejora de forma consistente sobre S0 en los tres modelos, mientras que S2 reduce tokens pero pierde accuracy al no recuperar en algunos casos que sí requerían evidencia. El meta-router S5 muestra que hay complementariedad real entre sistemas: con la política confidence-then-cost alcanza 81.4% usando 45% menos tokens que S3, aunque al ser post-hoc no es un sistema deployable tal cual. **En robustez, S3 lidera en corpus limpio y con ruido aleatorio, pero es S1 el que resulta más estable frente a distractores adversariales.**




Figura: Trade-off entre accuracy y costo (tokens) para los sistemas S0-S3 en los tres modelos evaluados. Mayor recuperación de evidencia mejora la accuracy, pero a mayor costo.

Modelo	S0	S1	S2	S3	Δ S3 vs S0
gpt-4.1-mini	0.404	0.558	0.468	0.622	+0.218
gpt-5-nano	0.554	0.716	0.630	0.744	+0.190
gpt-5-mini	0.706	0.782	0.754	0.808	+0.102

Tabla: Accuracy por sistema y modelo sobre las 500 preguntas de MuSiQue-MC-500. S3 (recuperación activa) es el mejor sistema en los tres modelos, con mejoras de 10 a 22 puntos sobre S0.




Figura: Robustez de S1, S2 y S3 ante corpus limpio, con ruido aleatorio y con distractores adversariales (gpt-5-mini, n=100). S3 lidera en clean y noisy, pero S1 resulta más estable ante adversarial.

CONCLUSIONES

El hallazgo central es que RAG no es una decisión binaria: la pregunta relevante es cuándo recuperar, cuánto contexto pagar y cuándo auditar la evidencia. S1 funciona como baseline simple y estable, S3 maximiza accuracy en escenarios limpios pero es más frágil ante ruido, y S5 demuestra que combinar estrategias tiene margen de mejora real. El valor de RAG además depende fuertemente del modelo base: los modelos más chicos ganan más de la recuperación, pero también calibran peor cuándo activarla.

TRABAJO FUTURO

- Entrenar un router online que decida qué sistema usar antes de ejecutar todos los candidatos.
- Extender la evaluación de robustez a más modelos y más preguntas (hoy solo gpt-5-mini, n=100).
- Evaluar con respuesta abierta (exact match, F1) en vez de solo multiple-choice.
- Calibrar el auditor S4 para reducir su tasa de abstención (hoy 100% en el subconjunto focalizado).

REFERENCIAS

- Lewis et al. (2020) – Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks
- Jiang et al. (2023) – Active Retrieval Augmented Generation (FLARE)
- Asai et al. (2024) – Self-RAG
- Trivedi et al. (2022) – MuSiQue
- Thorne et al. (2018) – FEVER